

# 《机器学习》期末课程设计题目

学期 2025-2026-2

专业年级： 计算机科学与技术 2023 级

学生从以下题目中选择一个完成。

## (1) 基于传统机器学习算法的数据集分类任务实现与对比分析

选取公开标准分类数据集（如鸢尾花数据集、葡萄酒数据集、心脏病诊断数据集），分别使用逻辑回归、支持向量机、决策树、K 近邻四种经典分类算法完成模型训练与预测；计算准确率、精确率、召回率等评价指标，绘制混淆矩阵，对比不同算法在该数据集上的分类效果、运行效率与适用场景，并结合数据集特征分析算法性能差异。

## (2) 基于无监督聚类算法的样本数据挖掘与可视化分析

针对用户行为、商品评分或图像特征等无标签数据集，分别实现 K-Means、DBSCAN 两种主流聚类算法，完成数据预处理、特征筛选、聚类模型训练；通过轮廓系数、肘部法则确定最优聚类数量，对聚类结果进行可视化展示，解读不同簇的样本分布规律与内在特征，探究两种聚类算法对异常样本、非球形分布数据的处理能力。

## (3) 基于神经网络的手写数字分类系统设计与调优

利用全连接神经网络搭建分类模型，选用手写数字数据集完成训练与测试；自主完成数据集划分、网络结构设计、激活函数与损失函数选型，尝试调整网络层数、神经元数量、学习率等超参数观察模型性能变化，分析过拟合现象并采用正则化、早停等方法优化模型，对比神经网络与传统分类算法的优劣，撰写设计思路、实验过程与总结报告。

## (4) 深度模型在后门攻击下的脆弱性评估

后门攻击是深度学习模型面临的一类严重安全威胁——攻击者在训练阶段植入隐蔽触发器，模型在正常样本上表现优异，但遇到含触发器的样本时会被定向操控。目前面向特定任务（图像分类、时间序列预测）的后门攻击防御方案缺乏系统性的脆弱性评估。实现 3-4 种主流后门攻击方法（BadNets、Blended 等），并在 2-3 种防御方法（Neural Cleanse、STRIP、Fine-pruning 等）下评估防御效果，分析不同攻击方法的脆弱性模式和防御的局限性。

## (5) 后门攻击中触发器位置的空间敏感性分析

现有后门攻击默认触发器放在图像固定位置（右下角等），但位置对攻击成功率影响多大？不同位置是否会被不同防御方法检测到？通过实验，调查后门攻击中触发器位置对攻击

效果和防御检测效果的影响。在 CIFAR-10 数据集上训练多个带有后门的神经网络模型，在不同网格位置植入相同的触发器图案，系统测量以下两个维度的指标：1)测量不同触发器位置下后门攻击的成功率变化；2)测量不同触发器位置下的模型被 Neural Cleanse 等防御方法检测出的难易程度。通过系统性实验量化触发器空间位置与攻击隐蔽性之间的权衡，并绘制热力图直观展示不同位置的空间敏感性分布。

#### （6）深度学习的解释方法之间的“一致性”评估

对同一样本，多种解释方法给出的解释是否一致？可解释深度学习领域需要对方法间一致性（也称为鲁棒性或共识度）进行关注。对图像分类任务，系统比较 4-5 种主流归因/可解释方法在相同输入和模型下的解释结果一致性。在 CIFAR-10 等数据集上训练 CNN（例如 ResNet-18 模型）；使用 Captum ([github.com/pytorch/captum](https://github.com/pytorch/captum)) 生成五种解释；计算解释之间的一致性。分析哪些特征、训练示例或概念对模型的预测有贡献，以及模型如何学习。聚类分析找出“一致同意”和“分歧最大”的样本/特征。

提交方式：

- a) 打包提交：课程设计报告 + 源代码 + 测试数据。
- b) 打包文件命名格式“学号列表\_姓名列表\_题目”，例如：“222024321182101,102,103\_张三,李四,王五\_XXX 题目”。
- c) 1-5 人为小组（报告中讲清分工）。
- d) 必要时，部分小组需要对课程设计进行讲解演示。
- e) 按照课程报告模板写作。
- f) 提交截止日期 2026 年 6 月 28 日。
- g) 上传 FTP 服务器：

[校内] 实验报告上传方式

ftp://172.18.5.102

用户名: chengpeng

密码: chengpeng

存放路径: /2025-2026-2/机器学习/